

What Happens Next? — Synthèse des modèles

Classification vidéo, 33 classes, $T = 4$ frames

Étienne Chevrolat

CSC_43M04_EP

May 29, 2026

Les différentes architectures testées


- model14_A : idée initiale **CNN 2D + temporal attention**.
- model15_A / model15_B : **R(2+1)D + transformer** ; 5_B avec TSM + 196 tokens spatio-temporels.
- videomae_v2 + model17_A : pretrain self-supervisé (94M params) puis finetune ViT-B avec LLDR.

Récapitulatif des meilleurs runs

Ckpt	Archi	Params	top-1	top-5	lat. ms/clip
best_model.pt	model1.2_A	12.9M	0.244	0.548	1.3
best_model_v2.pt	model2_A	17.8M	0.229	0.535	1.6
best_model_v6_5.pt	model5_B	39.8M	0.357	0.677	4.2
best_model_v6_8.pt	model5_B	39.8M	0.403	0.718	4.2
best_model_v6_10.pt	model5_B	39.8M	0.405	0.715	4.2
best_model_v6_12.pt	model5_B	39.8M	0.406	0.719	4.2
best_model_v6_101.pt	model5_B	42.9M	0.391	0.701	4.3
best_model_v7_lldr_v2	model7_A	86.3M	0.401	0.715	9.2
best_model_v7_lldr_diverse	model7_A	86.3M	0.409	0.736	9.2

Précision vs taille / latence


real val top-1



model15_B reste **2× plus petit et 2× plus rapide** que model17_A pour une accuracy quasi-équivalente.

model4_A — CNN 2D + temporal attention

Idée. Un CNN 2D produit *un vecteur par frame* ; un mini-transformer agrège les $T+1$ tokens.



Hyperparams.


- embed_dim = 512, 8 têtes
- DropPath linéaire 0 → 0.15
- ~15M params

Comment améliorer ?

- 4 tokens → l'attention est un avg-pool pondéré.
- Pas de mélange temporel *avant* le GAP.
- ⇒ conduit à [model5_A](#) / [model5_B](#).

model5_A — R(2+1)D backbone + transformer temporel

Idée. CNN **R(2+1)D** : mélange temporel intégré aux convs (conv (1, 3, 3) + (3, 1, 1)).




Limites observées.

- Spatial AvgPool après stage 4 **jette à nouveau** l'information localisée.
- L'attention temporelle voit toujours 5 tokens (CLS + 4 frames).
- $\Rightarrow$ **flatten plutôt qu'avg-pooler** : c'est model5_B.

model5_B — 3 changements ciblés vs model5_A

- 1 **Flatten spatio-temporel** après stage 4 : $4 \times 7 \times 7 = 196$ tokens.
- 2 **TSM** (Temporal Shift Module) dans chaque BasicBlock : décale $1/8$ des canaux de ± 1 en T , **zéro** paramètre.
- 3 **Attention pooling** (vecteur query appris) à la place du CLS.



39.78M params, 4.17 ms/clip A100, FP32, single-clip forward.

model5_B — entraînement (run v6_12, best)

Recette d'entraînement.


- AdamW, lr $2 \cdot 10^{-5}$, cosine
- batch 32 (single GPU)
- grad clip 1.0, AMP bf16
- MixUp $\alpha=0.3$, CutMix $\alpha=0.5$ (prob 0.2 / 0)
- LS 0.1, dropout3D 0.3, transformer drop 0.2
- DropPath 0.1 backbone, 0.3 transformer
- Backbone init : best_model_v3_36.pt (R(2+1)D pretrained sur le challenge)
- Freeze backbone 5 epochs, puis unfreeze
- 80 epochs (~ 6 h sur A100)

Résultats (re-évalués sur le *vrai* val).

Métrique	Valeur
Params totaux	39.78 M
REAL val top-1	0.406
REAL val top-5	0.719
Latence forward	4.17 ms/clip
Empreinte ckpt	159 MB

Meilleur modèle *from scratch* (i.e. sans pretrain externe). Le pretrain MAE n'apporte qu'**+0.3 pts** (cf. model7_A) pour $2,2\times$ plus de paramètres.


model5_B — runs comparés (REAL val top-1)



Sauts visibles : v6_5→v6_6 (correction du bug *fake val*) ; v6_7→v6_8 (DDP 2 GPU, batch effectif 32).


VideoMAE V2 — pretrain self-supervisé

Objectif. Apprendre des features vidéo génériques en **reconstruisant les pixels masqués** d'un tubelet. Aucune étiquette.



Ckpt	mask	epochs	lr	loss finale (recon)
mae_70.pt	0.75	196	1.5e-4	0.304
mae_mask09_v2.pt	0.90	200+	1e-4	0.320


Pretrain — courbes de loss (W&B)



Données extraites des logs W&B iqlvv5j8 (mask 0.75 fresh), 4ygd8w3y+ap3hg81c+jx29uvim (mask 0.90 cumulé), sovku5rx (mae_70). mask=0.90 ralentit la convergence (tâche plus dure) mais converge in fine plus bas.

model7_A — finetune de l'encoder MAE pour classification

Idée. Archi rigoureusement identique à l'encoder MAE → `load_from_videomae_v2()` recopie 100 % du backbone.



Layer-wise LR decay (LLDR).


$$\text{lr}(\ell) = \text{lr}_{\text{base}} \cdot \gamma^{(D+1-\ell)}, \quad \gamma = 0.75$$

- head : full LR
- block 11 : $\times 0.75$
- patch_embed : $\times 0.75^{13} \approx 1/24$
- $\Rightarrow$ couches basses quasi-gelées

Recette MAE-textbook.

- AdamW, $\beta_2=0.95$, wd 0.05
- lr base head $2 \cdot 10^{-4}$, warmup 5 ep, cosine $\rightarrow 10^{-6}$
- MixUp 0.8, CutMix 1.0 (prob 0.5/0.5)
- LS 0.1, DropPath 0.2
- 50 epochs, batch 24, 86.3M params


Finetune — LLDR ou pas LLDR ? (W&B, REAL val top-1)



Sans LLDR, l'init ViT-B se fait détruire (head trop forte qui « écrase » les features pretrain) : on ne dépasse pas 0.26 même après 50 epochs.

Avec LLDR sur la même init mae_70.pt, on atteint **0.397** à l'epoch 47.


Finetune — init mae70 vs mae90 vs mae90 finetune long



Toutes courbes extraites de W&B (zan03dr2, pndm6gsf, 2if09wfz, gpxf7uzm). **mae_70 (mask=0.75) bat mae_90** en finetune ; le run final **lldr_diverse** reprend lldr_v2 et le pousse à 0.409 grâce à un resume + augs diversifiées.

Coût d'entraînement vs accuracy

real val top-1



temps total entraînement (h, A

- Le **vrai coût** de model17_A inclut le pretrain MAE (~ 22 h pour mae_70).
- En coût total, model15_B est $\sim 5\times$ **plus efficace** pour 0.3 pts de moins.

Ce qui ressort de ces expériences

Ce qui paie

- **Prior 3D** (R(2+1)D) » attention 2D pure.
- **TSM** : gratuit, indispensable avec $T=4$.
- **Plus de tokens** (196 vs 5) : laisse l'attention exister.
- **Attention pooling** > CLS pour grand N .
- **LLDR** *indispensable* pour finetuner un ViT pretrainé MAE.
- **Vrai val** pour sélectionner le checkpoint.

Ce qui n'a pas marché

- Pretrain MAE court (≤ 200 ep) : ViT-B reste limite vs R(2+1)D 40M.
- `mask_ratio=0.90` : finetune moins bon (-7 pts vs mask 0.75).
- Empiler dropout / drop_path sans aug données : plafonne.
- Run `fresh_500` : warm-restart mal configuré ($\rightarrow 0.027$).
- Finetune *sans* LLDR : plafonne à 0.26.

Meilleur modèle

model17_11dr_diverse : ViT-B finetune depuis MAE
86.3 M params, top-1 **0.409**, top-5 **0.736**

Mais : model15_B v6_12 suit à 0.3 pts, avec **39.8 M** params seulement.